PROPOSAL HACKATHON FINDIT! 2026

Track A: The Edge Vision (Computer Vision)

RescueVision Edge:

Lightweight Sovereign AI for On-Device Victim Localization in Post-Disaster Aerial Assessment

Disusun oleh:

Tim: Hamba tuhan yang mahaesa

Nama	NIM
Wafa Bila Syaefurokhman	442023611098
Farrel Ghozy Affifudin	452024611053
Fatih Jawwad Al Mumtaz	452024611047
Sabri Mutiur Rahman	442023611104

Program Studi Teknik Informatika

Universitas Darussalam Gontor (UNIDA)

2026

DAFTAR ISI

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Indonesia merupakan salah satu negara dengan tingkat kerawanan bencana tertinggi di dunia. Berdasarkan data Badan Nasional Penanggulangan Bencana (BNPB), Indonesia mencatat lebih dari 3.500 kejadian bencana setiap tahunnya yang berdampak pada jutaan jiwa masyarakat. Posisi geografis Indonesia yang berada di Cincin Api Pasifik (Ring of Fire) menjadikan negara ini rentan terhadap berbagai bencana alam, mulai dari gempa bumi, tsunami, letusan gunung berapi, banjir, hingga tanah longsor.

Dalam situasi pascabencana, operasi pencarian dan pertolongan (Search and Rescue/SAR) merupakan fase kritis yang menentukan keselamatan korban. Setiap menit yang terbuang dalam proses pencarian berpotensi merenggut nyawa. Namun, tim SAR seringkali menghadapi hambatan signifikan: kondisi medan yang berbahaya, keterbatasan jangkauan visual di area terdampak yang luas, serta risiko keselamatan personel yang tinggi apabila masuk ke zona berbahaya tanpa informasi yang memadai.

Penggunaan drone dalam survei udara pascabencana telah menjadi solusi yang semakin populer dalam beberapa tahun terakhir. Drone memungkinkan tim SAR untuk memperoleh gambaran udara area terdampak secara cepat tanpa harus menempatkan personel dalam bahaya. Namun, analisis citra yang dihasilkan drone masih dilakukan secara manual oleh operator — sebuah proses yang lambat, melelahkan, dan rentan terhadap kesalahan manusia (human error). Operator yang kelelahan setelah jam-jam pertama pascabencana berpotensi melewatkan keberadaan korban yang tersembunyi atau berada dalam kondisi tidak bergerak.

Selain itu, solusi analisis citra berbasis kecerdasan buatan yang ada saat ini umumnya bergantung pada cloud computing — mengirimkan data citra ke server eksternal untuk diproses. Pendekatan ini memiliki dua kelemahan fatal dalam konteks bencana: pertama, jaringan internet di wilayah terdampak bencana seringkali lumpuh; kedua, pengiriman data citra lokasi korban ke server pihak ketiga menimbulkan permasalahan kedaulatan data yang krusial dalam operasi SAR pemerintah.

Hingga saat ini, belum tersedia sistem deteksi korban berbasis kecerdasan buatan yang memenuhi tiga syarat sekaligus: (1) ringan dan efisien secara komputasi sehingga dapat berjalan pada perangkat standar tanpa infrastruktur khusus, (2) mampu beroperasi sepenuhnya secara luring (offline) tanpa ketergantungan jaringan, dan (3) mampu menghasilkan informasi lokasi korban yang dapat langsung ditindaklanjuti oleh tim SAR di lapangan.

Kesenjangan inilah yang menjadi landasan pengembangan RescueVision Edge — sebuah sistem visi komputer berbasis kecerdasan buatan yang dirancang khusus untuk memenuhi ketiga syarat tersebut dalam satu paket solusi yang komprehensif dan berdaulat secara teknologi.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana membangun sistem deteksi korban dari citra drone yang mampu berjalan sepenuhnya secara luring (offline) tanpa ketergantungan pada cloud computing maupun infrastruktur jaringan eksternal?
2. Bagaimana merancang arsitektur model computer vision yang memenuhi batasan sumber daya komputasi ketat — ukuran model maksimal 50 MB dan waktu inferensi maksimal 3 detik per citra pada CPU standar — tanpa mengorbankan akurasi deteksi yang memadai untuk operasi SAR?
3. Bagaimana menghasilkan keluaran sistem yang dapat langsung ditindaklanjuti oleh koordinator SAR, berupa koordinat geografis estimasi posisi korban yang diturunkan dari metadata GPS citra drone?

1.3 Tujuan

Tujuan pengembangan sistem RescueVision Edge adalah:

4. Membangun sistem deteksi korban pascabencana dari citra udara drone yang berjalan sepenuhnya secara luring, tanpa dependensi pada API atau layanan cloud eksternal apapun.
5. Mengembangkan model object detection berbasis YOLOv8n yang memenuhi seluruh batasan teknis (constraint) Track A: The Edge Vision — ukuran kurang dari atau sama dengan 50 MB, latensi kurang dari atau sama dengan 3 detik di CPU, dan kompatibilitas penuh dengan lingkungan CPU-only.
6. Menghasilkan keluaran sistem berupa bounding box deteksi korban beserta koordinat GPS estimasi posisi yang dapat langsung digunakan oleh tim SAR untuk menentukan prioritas zona pencarian.
7. Membuktikan bahwa sistem AI yang ringan, adaptif, dan berdaulat secara teknologi dapat dikembangkan untuk memperkuat ketahanan nasional dalam menghadapi situasi bencana, sejalan dengan tema "Digital Sovereignty: Empowering National Resilience with Adaptive Intelligence".

1.4 Manfaat

1.4.1 Bagi Tim SAR dan BASARNAS

Sistem ini memungkinkan analisis citra drone yang sebelumnya membutuhkan 10-30 menit per foto secara manual menjadi selesai dalam kurang dari 1 detik, serta memberikan koordinat estimasi lokasi korban yang dapat langsung dimasukkan ke perangkat GPS lapangan.

1.4.2 Bagi Kedaulatan Data Nasional

Seluruh pemrosesan dilakukan secara lokal — tidak ada data citra atau koordinat korban yang dikirimkan ke server pihak ketiga, menjaga kerahasiaan operasi SAR dan privasi korban sesuai dengan amanat Undang-Undang Perlindungan Data Pribadi (UU PDP No. 27 Tahun 2022).

1.4.3 Bagi Pengembangan Teknologi AI Nasional

Penelitian ini mendemonstrasikan bahwa mahasiswa Indonesia mampu mengembangkan sistem AI kelas dunia yang adaptif terhadap batasan teknis ekstrem, dengan memanfaatkan ekosistem open source global secara berdaulat dan mandiri.

BAB 2 METODOLOGI AI

2.1 Dataset

2.1.1 Sumber Data

Dataset yang digunakan dalam penelitian ini adalah VisDrone-DET 2019 (Task 1: Object Detection in Images), dataset benchmark standar untuk deteksi objek pada citra drone yang dikembangkan oleh Lab AISKYEYE, Tianjin University. Dataset ini bersifat publik dan dapat diakses melalui repositori resmi di https://github.com/VisDrone/VisDrone-Dataset.

VisDrone-DET 2019 terdiri dari lebih dari 10.000 citra statis hasil tangkapan drone dari berbagai ketinggian, kondisi pencahayaan, dan kepadatan objek. Dataset ini menyediakan anotasi bounding box untuk 10 kelas objek. Dalam penelitian ini, hanya kelas pedestrian (kelas 1) dan people (kelas 2) yang digunakan dan digabungkan menjadi satu kelas tunggal berlabel pedestrian, sesuai dengan fokus sistem pada deteksi manusia dari perspektif udara pascabencana.

2.1.2 Pemisahan Data

Pemisahan data dilakukan sebelum preprocessing apapun untuk memastikan tidak ada kebocoran data (data leakage) antara set pelatihan dan pengujian. Skema pemisahan mengikuti pembagian resmi VisDrone-DET 2019:

Split	Jumlah Citra	Keterangan
Train	5.655	Disimpan di train_data/images/train/
Validasi	530	Disimpan di train_data/images/val/
Test	1.265	Disimpan di test_data/images/
Total	7.450	

Verifikasi bebas kebocoran data dilakukan secara otomatis menggunakan skrip verify_split.py yang memeriksa duplikasi berdasarkan nama file dan hash MD5 konten file. Hasil verifikasi menunjukkan nol tumpang tindih antara train_data/ dan test_data/ (lihat docs/leakage_report.txt).

2.1.3 Praproses dan Augmentasi Data

Praproses citra meliputi konversi anotasi dari format VisDrone ke format YOLO (koordinat bounding box dinormalisasi terhadap dimensi citra), serta penyaringan anotasi dengan score = 0 (wilayah yang diabaikan) dan bounding box berdimensi nol. Augmentasi data diterapkan secara online selama pelatihan menggunakan pipeline bawaan Ultralytics YOLOv8:

Teknik Augmentasi	Parameter	Rasional
Mosaic	p=1.0	Kritis untuk deteksi objek kecil; menggabungkan 4 citra

Teknik Augmentasi	Parameter	Rasional
Mixup	p=0.1	Regularisasi; mencampur dua citra dengan bobot acak
HSV Hue	±0.015	Invariansi terhadap variasi warna cahaya
HSV Saturation	±0.7	Robustness terhadap kondisi pencahayaan berbeda
HSV Value	±0.4	Adaptasi terhadap variasi kecerahan (siang/senja/berawan)
Horizontal Flip	p=0.5	Invariansi orientasi kiri-kanan
Vertical Flip	p=0.0	Dinonaktifkan; konteks ketinggian drone tidak ambigu

2.2 Pemilihan Arsitektur Model

2.2.1 Eksperimen Baseline: YOLOv5n

Sesuai protokol yang ditetapkan panitia, eksperimen dimulai dengan melatih YOLOv5n (nano) sebagai baseline. YOLOv5n dipilih karena merupakan varian terkecil dari keluarga YOLOv5 dengan arsitektur CSP (Cross Stage Partial) Darknet yang ringan (~7.5 MB ONNX). Model dilatih dengan konfigurasi identik: 100 epoch, batch size 16, resolusi input 640x640 piksel, pada GPU NVIDIA GeForce RTX 4060 (8 GB VRAM).

Hasil pelatihan YOLOv5n mencapai mAP@0.5 = 0.4684 pada set validasi (epoch terbaik: 93/100).

2.2.2 Perbandingan dengan YOLOv8n

Setelah baseline ditetapkan, eksperimen dilanjutkan dengan melatih YOLOv8n (nano) menggunakan konfigurasi yang identik. YOLOv8n menggunakan arsitektur C2f (Cross Stage Partial with 2 fast layers) dengan detection head berbasis anchor-free, berbeda dari YOLOv5n yang masih menggunakan anchor-based detection.

Metrik	YOLOv5n	YOLOv8n	Delta
mAP@0.5 (terbaik)	0.4684	0.5280	+0.0596
mAP@0.5:0.95 (terbaik)	0.1728	0.2159	+0.0431
Ukuran ONNX (MB)	7.49	11.70	+4.21
Latensi CPU rata-rata (ms)	18.0	30.4	+12.4
Latensi CPU maksimum (ms)	19.8	38.1	+18.3
Epoch konvergensi	93/100	90/100	comparable

2.2.3 Justifikasi Pemilihan YOLOv8n

Berdasarkan hasil eksperimen, YOLOv8n dipilih sebagai arsitektur final dengan tiga justifikasi utama.

Pertama, YOLOv8n mencapai mAP@0.5 = 0.5280, unggul 5.96 poin persentase dibandingkan YOLOv5n (0.4684). Pada domain deteksi objek kecil seperti citra drone, peningkatan 6 poin mAP memiliki implikasi praktis yang signifikan terhadap kemampuan sistem menemukan korban.

Kedua, detection head berbasis anchor-free mengeliminasi bias terhadap ukuran anchor yang telah dikonfigurasi sebelumnya, sehingga lebih adaptif terhadap variasi skala objek ekstrem yang umum pada citra drone. Backbone C2f memberikan representasi fitur yang lebih kaya dibandingkan CSP Darknet YOLOv5 pada jumlah parameter yang setara (~3M parameter).

Ketiga, meskipun YOLOv8n memiliki latensi CPU lebih tinggi (38.1ms vs 19.8ms), keduanya jauh di bawah batas constraint 3.000ms. Ukuran model YOLOv8n (11.70 MB) juga tetap dalam batas constraint 50 MB.

2.3 Arsitektur Model Final

Komponen	Spesifikasi
Arsitektur	YOLOv8n (C2f backbone, anchor-free head)
Jumlah parameter	3.011.043
GFLOPs	8.2
Jumlah kelas	1 (pedestrian)
Resolusi input	640 x 640 piksel
Format weights	ONNX opset 17 (model/best.onnx)
Ukuran model	11.70 MB

2.4 Konfigurasi Pelatihan

Parameter	Nilai	Rasional
Optimizer	AdamW	Konvergensi lebih stabil untuk fine-tuning
Learning rate awal	0.002	Ditentukan otomatis oleh Ultralytics
Weight decay	0.0005	Regularisasi L2
Warmup epochs	3	Stabilisasi awal pelatihan
Batch size	16	Optimal untuk VRAM 8 GB
Epochs	100	Dengan early stopping patience=20
AMP	Aktif	Automatic Mixed Precision untuk efisiensi

Parameter	Nilai	Rasional
		GPU
Close mosaic	10	Nonaktifkan mosaic di 10 epoch terakhir

Pelatihan dilakukan pada GPU NVIDIA GeForce RTX 4060 (8 GB VRAM, CUDA 12.1) dengan durasi ~80 menit untuk 100 epoch. Pretrained weights dari dataset COCO digunakan sebagai titik awal (transfer learning), dengan 355/355 layer berhasil ditransfer.

2.5 Evaluasi Model

2.5.1 Metrik Evaluasi

Evaluasi dilakukan menggunakan metrik standar deteksi objek:

- mAP@0.5: mean Average Precision pada IoU threshold 0.5 — metrik utama
- mAP@0.5:0.95: mean Average Precision dirata-ratakan pada IoU threshold 0.5-0.95 dengan step 0.05
- Precision: rasio prediksi positif yang benar terhadap seluruh prediksi positif
- Recall: rasio prediksi positif yang benar terhadap seluruh ground truth positif

2.5.2 Hasil Evaluasi Final

Metrik	Nilai
mAP@0.5 (epoch terbaik, epoch 90)	0.5280
mAP@0.5:0.95	0.2159
Precision	0.613
Recall	0.452

2.5.3 Analisis Overfitting

Konvergensi terjadi pada epoch 90 dari maksimum 100 epoch, dengan early stopping tidak terpicu (model masih meningkat hingga akhir). Selisih antara training loss dan validation loss terjaga kecil sepanjang pelatihan, mengindikasikan tidak ada overfitting signifikan. Penggunaan augmentasi agresif (mosaic, mixup) dan weight decay 0.0005 berkontribusi terhadap generalisasi model.

BAB 3 KEPATUHAN CONSTRAINT

Bab ini menjelaskan secara rinci bagaimana sistem RescueVision Edge memenuhi setiap poin constraint Track A: The Edge Vision yang ditetapkan panitia Hackathon FindIT! 2026, beserta bukti teknis yang dapat diverifikasi.

3.1 Constraint Track A: The Edge Vision

C-A1: Ukuran Model ≤ 50 MB

Requirement: Bobot model final (file .pt / .h5 / .onnx) tidak boleh melebihi 50 MB.

Model final diekspor dalam format ONNX menggunakan Ultralytics export pipeline dengan konfigurasi opset=17, simplify=True, dan dynamic=False. Proses simplifikasi graf dilakukan menggunakan onnxslim 0.1.90 yang menggabungkan operasi BatchNorm, menghapus node redundan, dan mengoptimalkan struktur komputasi tanpa mengubah output model.

File	Ukuran	Status
runs/.../best.pt (PyTorch)	6.23 MB	—
model/best.onnx (submission)	11.70 MB	PASS ✓

Ukuran 11.70 MB berada 76.6% di bawah batas maksimum 50 MB, memberikan margin yang sangat besar. Pilihan arsitektur YOLOv8n dengan depth_multiple=0.33 dan width_multiple=0.25 secara fundamental memastikan ukuran model tetap kecil (3.011.043 parameter, 8.2 GFLOPs).

C-A2: Kompatibilitas Platform (CPU-only capable)

Requirement: Model wajib tetap dapat berjalan di lingkungan CPU-only.

Seluruh pipeline inferensi pada inference.ipynb menggunakan ONNX Runtime dengan CPUExecutionProvider secara eksplisit. Tidak ada dependensi terhadap CUDA, cuDNN, atau akselerasi GPU apapun dalam kode inferensi.

Pemisahan antara environment pelatihan (GPU) dan inferensi (CPU) dilakukan secara arsitektural: pelatihan menggunakan PyTorch dengan device=0 (CUDA), sedangkan inferensi sepenuhnya menggunakan ONNX Runtime CPU. Format ONNX dipilih karena portabilitasnya — model dapat dijalankan pada mesin apapun yang memiliki Python dan onnxruntime tanpa dependensi CUDA.

C-A3: Kecepatan Inferensi ≤ 3.000 ms per Sampel (CPU, i5 Gen 8+)

Requirement: Waktu inferensi per satu sampel input tidak boleh melebihi 3 detik pada mesin CPU standar (minimum Intel Core i5 Gen 8 / setara). Pengukuran dilakukan pada kondisi CPU tanpa akselerasi GPU.

Keputusan Desain	Nilai	Dampak
Arsitektur	YOLOv8n (nano)	~8x lebih cepat dari YOLOv8m

Keputusan Desain	Nilai	Dampak
Resolusi input	640 x 640 px	Standar optimal accuracy/speed
Format inferensi	ONNX Runtime	Lebih cepat dari PyTorch CPU mode
Simplifikasi graf	simplify=True	Mengurangi overhead komputasi
Input shape	Fixed (non-dynamic)	Waktu inferensi deterministik

Hasil benchmark CPU (Intel Core i5-12400F, CPUExecutionProvider, 30 sampel dari test_data/):

Metrik	Nilai	Batas Constraint	Status
Latensi rata-rata	31.9 ms	—	—
Latensi P95	33.9 ms	—	—
Latensi maksimum	38.1 ms	3.000 ms	PASS ✓

Latensi maksimum 38.1 ms berada 98.7% di bawah batas constraint, memberikan margin 2.962 ms. Bahkan pada prosesor i5 Gen 8 yang lebih lambat ~2.5x dari i5-12400F, estimasi latensi maksimum adalah ~95 ms — masih jauh di bawah 3.000 ms.

C-A4: Framework

Requirement: Model wajib menggunakan salah satu framework berikut: PyTorch, TensorFlow/Keras, atau ONNX Runtime.

Tahap	Framework	Versi
Pelatihan	PyTorch via Ultralytics	torch 2.5.1+cu121
Inferensi	ONNX Runtime	onnxruntime 1.23.2

Alur PyTorch -> ONNX -> ONNX Runtime merupakan workflow deployment standar yang direkomendasikan secara resmi. Tidak ada framework di luar daftar yang digunakan sebagai komponen inti sistem.

C-A5: Offline Total

Requirement: Seluruh proses inferensi berjalan secara offline (localhost). Dilarang menggunakan API eksternal atau cloud inference dalam pipeline inferensi.

Audit dependensi inference.ipynb mengkonfirmasi tidak ada library atau panggilan jaringan eksternal. Dependensi yang digunakan: onnxruntime (inferensi lokal), numpy (komputasi numerik), opencv-python (pemrosesan citra lokal), matplotlib (visualisasi lokal), dan pathlib (operasi file lokal). Tidak ada imports dari requests, urllib, google-cloud-vision, boto3, openai, maupun huggingface_hub inference API.

Model dimuat dari file lokal model/best.onnx pada setiap sesi inferensi. Sistem dapat beroperasi penuh tanpa koneksi internet, sesuai dengan skenario penggunaan di area bencana yang seringkali mengalami gangguan infrastruktur jaringan.

3.2 Constraint Umum

CU-1: Struktur File

File/Folder	Status	Keterangan
proposal.pdf	✓	Dokumen ini
training.ipynb	✓	Log epoch 1-100 visible
inference.ipynb	✓	Script bersih, siap dijalankan
model/best.onnx	✓	11.70 MB, ONNX opset 17
train_data/	✓	5.655 train + 530 val images & labels
test_data/	✓	1.265 images & labels, terpisah

CU-2: Reproducibility

Model dapat dilatih ulang sepenuhnya dari training.ipynb dengan dataset yang sama. Seluruh hyperparameter tercatat di sel konfigurasi notebook. seed=0 digunakan untuk determinisme. Inferensi dapat dijalankan di lingkungan CPU-only tanpa GPU.

CU-3: Bahasa Kode

Seluruh kode ditulis dalam Python 3.10 menggunakan library standar (PyTorch, Ultralytics, ONNX Runtime, OpenCV, NumPy). Tidak ada komponen dalam bahasa lain.

CU-4: Larangan Cloud Inference

Tidak ada API inferensi cloud yang digunakan dalam pipeline utama. Lihat C-A5 untuk audit lengkap.

3.3 Ringkasan Kepatuhan

Constraint	Requirement	Hasil	Status
C-A1	≤ 50 MB	11.70 MB	PASS ✓
C-A2	CPU-only capable	CPUExecutionProvider	PASS ✓
C-A3	≤ 3.000 ms (CPU)	38.1 ms maks	PASS ✓
C-A4	PyTorch/TF/ONNX	PyTorch + ONNX Runtime	PASS ✓
C-A5	Offline total	Zero external calls	PASS ✓
CU-1	Struktur file lengkap	Semua file tersedia	PASS ✓

Constraint	Requirement	Hasil	Status
CU-2	Reproducible	seed=0, config terdokumentasi	PASS ✓
CU-3	Python utama	Python 3.10 (100%)	PASS ✓
CU-4	No cloud inference	Zero API calls	PASS ✓

Seluruh constraint wajib terpenuhi dengan margin yang signifikan, khususnya pada C-A1 (model 76.6% lebih kecil dari batas) dan C-A3 (inferensi 98.7% lebih cepat dari batas).

BAB 4 RANCANGAN SISTEM & BISNIS

4.1 Arsitektur Sistem

4.1.1 Gambaran Umum

RescueVision Edge dibangun sebagai sistem berbasis web yang berjalan sepenuhnya secara lokal (localhost) pada laptop koordinator lapangan. Sistem tidak memerlukan koneksi internet dalam operasionalnya, sesuai dengan skenario nyata di wilayah bencana yang seringkali mengalami gangguan infrastruktur jaringan.

Arsitektur sistem terdiri dari tiga komponen utama: Input Layer (foto drone dengan GPS EXIF), Processing Layer (FastAPI backend + YOLOv8n ONNX + EXIF Parser + Coordinate Mapper), dan Output Layer (Web Dashboard dengan bounding box, koordinat GPS, tabel korban, dan ekspor CSV/JSON).

4.1.2 Alur Operasional

Fase 1 — Pengumpulan Data Udara: Operator drone menerbangkan wahana DJI di atas area terdampak dan merekam citra udara. Drone DJI secara otomatis menyimpan koordinat GPS, ketinggian terbang, dan sudut gimbal dalam metadata EXIF setiap foto yang dihasilkan.

Fase 2 — Transfer & Analisis: Setelah mendarat, operator mentransfer foto dari kartu memori (SD card) ke laptop koordinator. Foto kemudian diunggah ke antarmuka web RescueVision Edge yang berjalan di localhost. Sistem memproses setiap foto secara otomatis: membaca metadata EXIF, menjalankan inferensi model YOLOv8n, dan menghitung koordinat geografis setiap korban yang terdeteksi.

Fase 3 — Tindak Lanjut SAR: Koordinator SAR membaca hasil deteksi berupa peta visual dengan bounding box dan tabel koordinat GPS per korban. Informasi ini diteruskan ke tim SAR di lapangan melalui radio atau perangkat GPS untuk menentukan prioritas zona pencarian.

4.1.3 Kalkulasi Koordinat Korban

Setiap foto DJI menyimpan metadata EXIF yang mencakup GPSLatitude, GPSLongitude, RelativeAltitude, dan GimbalYawDegree. Dari metadata ini, sistem menghitung koordinat geografis setiap korban menggunakan estimasi Ground Sampling Distance (GSD):

GSD = (sensor_width x altitude) / (focal_length x image_width)

Offset piksel dari pusat foto ke pusat bounding box dikonversi ke meter menggunakan GSD, kemudian dikonversi ke offset koordinat geografis. Output koordinat memiliki akurasi estimasi plus minus 5-15 meter pada ketinggian terbang 50-100 meter, cukup untuk menentukan zona pencarian SAR.

4.2 Rancangan Teknologi (Tech Stack)

Komponen	Teknologi	Alasan Pemilihan
Backend API	FastAPI (Python)	Ringan, async, mudah diintegrasikan
AI Inference	ONNX Runtime	CPU-only, offline, <40ms per foto

Komponen	Teknologi	Alasan Pemilihan
EXIF Parser	piexif / Pillow	Akses GPS metadata foto DJI
Frontend	React + Vite	Modern, modular, siap Dynamic Injection
Visualisasi Map	Leaflet.js	Peta offline tanpa API eksternal
Data Export	CSV + JSON	Kompatibel dengan GPS tools & GIS
Komunikasi	REST API (localhost)	Modular, siap menerima Runtime Variable

4.2.1 Desain API (Endpoint Utama)

Endpoint POST /detect menerima file gambar (multipart/form-data) dan mengembalikan JSON berisi daftar deteksi dengan id, confidence, bounding box, koordinat GPS, total korban, dan waktu inferensi. Endpoint POST /detect/batch memproses multiple file sekaligus. Endpoint GET /export/csv mengekspor koordinat semua korban. Endpoint GET /health mengembalikan status sistem dan versi model.

Endpoint POST /inject dirancang khusus untuk menerima Runtime Variable dari panitia pada Tahap 3, memungkinkan update parameter (confidence threshold, resolusi input, dll.) secara real-time tanpa restart sistem.

4.3 Antarmuka Pengguna (UI/UX)

Antarmuka dirancang untuk dua peran pengguna. Operator Drone membutuhkan drag & drop upload foto, progress bar pemrosesan, dan preview foto dengan bounding box overlay. Koordinator SAR membutuhkan tabel korban dengan koordinat GPS, peta Leaflet.js dengan marker per korban, tombol export CSV, dan ringkasan total korban per zona.

4.4 Rancangan Integrasi Tahap 3

Sesuai mekanisme Dynamic Injection Tahap 3, sistem dirancang dengan arsitektur modular yang dapat menerima variabel atau logika tambahan tanpa crash. Seluruh parameter sistem disimpan dalam file config.json yang dapat dimodifikasi tanpa mengubah kode inti. Endpoint /inject menerima payload JSON berisi parameter name dan value, memperbarui config secara real-time, dan mengembalikan konfirmasi update.

Dengan arsitektur ini, panitia dapat menginjeksi perubahan apapun saat countdown dimulai tanpa menyebabkan crash pada sistem. Ini juga membuktikan bahwa sistem tidak dibangun secara hardcoded (pre-built) karena seluruh parameter dapat disesuaikan secara dinamis.

4.5 Analisis Dampak & Keberlanjutan

4.5.1 Dampak Sosial

RescueVision Edge secara langsung mengatasi tiga hambatan utama dalam operasi SAR pascabencana Indonesia. Kecepatan Respons: analisis citra manual membutuhkan 10-30 menit per foto, sedangkan RescueVision Edge menyelesaikannya dalam kurang dari 1 detik.

Kedaulatan Data: tidak ada data yang dikirim ke server eksternal, menjaga kerahasiaan operasi. Aksesibilitas: model berjalan di laptop standar tanpa GPU khusus, tidak memerlukan infrastruktur mahal.

4.5.2 Target Pengguna

Segmen	Deskripsi	Estimasi Pengguna
BASARNAS	Badan SAR Nasional Indonesia	4.800 personel
BPBD Provinsi	Badan Penanggulangan Bencana Daerah	34 provinsi
TNI/Polri SAR Unit	Unit khusus SAR militer dan kepolisian	~2.000 personel
NGO Kemanusiaan	Organisasi kemanusiaan bencana	50+ organisasi

4.5.3 Analisis Kompetitor

Solusi	Kelemahan vs RescueVision Edge
Google Vision API	Membutuhkan internet, data dikirim ke cloud
AWS Rekognition	Biaya per-request, tidak tersedia di area bencana
Analisis manual	10-30 menit/foto, rentan human error, fatigue
Sistem drone komersial	Harga >$50.000, terikat vendor spesifik

RescueVision Edge adalah satu-satunya solusi yang menggabungkan akurasi AI (mAP@0.5 = 0.528), kecepatan inferensi (<40ms CPU), dan kedaulatan data penuh dalam satu paket yang dapat berjalan di laptop koordinator lapangan tanpa koneksi internet.

4.5.4 Rencana Keberlanjutan

Jangka Pendek (0-6 bulan): Pengujian lapangan bersama unit SAR lokal, penyempurnaan kalkulasi koordinat GPS berdasarkan data lapangan nyata, dan penambahan dukungan format video (analisis frame-by-frame).

Jangka Menengah (6-18 bulan): Integrasi dengan sistem Ground Control Station DJI, penambahan kelas deteksi (kendaraan terdampak, struktur runtuh), dan pengembangan versi mobile untuk koordinator lapangan.

Jangka Panjang (18+ bulan): Kolaborasi dengan BASARNAS dan BPBD untuk deployment nasional, penelitian peningkatan akurasi dengan data bencana Indonesia spesifik, dan potensi integrasi dengan sistem peringatan dini BMKG.

4.6 Etika Data & Privasi

Seluruh data citra dan koordinat korban diproses secara lokal dan tidak pernah meninggalkan perangkat operator. Sistem tidak menyimpan log inferensi secara permanen — data sesi dihapus otomatis saat aplikasi ditutup.

Model YOLOv8n dilatih menggunakan dataset publik VisDrone-DET 2019 yang tidak mengandung data identitas personal. Output sistem berupa koordinat lokasi, bukan identitas individu, sehingga tidak melanggar regulasi perlindungan data pribadi (UU PDP No. 27 Tahun 2022).